

TeuB: de una secuencia sin etiqueta a un ranking de ligandos

Evolución y Diseño de Proteínas 2027-1 · jmanuel@ibt.unam.mx

Numeración: cadena madura 1-335. El residuo 1 es la D de DDTIA, que corresponde al residuo 28 del precursor. **Panel:** 15 ligandos elegidos a partir de Foldseek, más D-treitol (3VB), que viene del panel del tutorial; en total, 16. **Métodos:** AutoDock Vina 1.2 (local) y Boltz-2 (ColabFold2, sin plantillas).

1 · El ranking

Vina: la mejor pose de cada semilla, promediada sobre 3 semillas (101, 202, 303), $\pm$ desviación estándar. Boltz-2: ipTM promedio de los 15 modelos (semillas 1-3 $\times$ 5 muestras), $\pm$ desviación estándar. Los ligandos marcados con * son señuelos. **Empates** según el criterio de la §2: en Vina no hay ninguno; en Boltz, los 10 del top-10 empatan con el primero, y también GAL y PAV.

#	Vina	kcal/mol	#	Boltz-2	ipTM (todos empatados con el 1.º)
1	XYP β -D-xilopiranososa	-6.408 ± 0.008	1	AHR α -L-arabinofuranosa	0.975 ± 0.008
2	ARA α -L-arabinopiranososa	-6.145 ± 0.012	2	BDR β -D-ribofuranosa	0.973 ± 0.012
3	HPA hipoxantina*	-6.102 ± 0.004	3	GZL β -D-galactofuranosa	0.963 ± 0.007
4	INS <i>mio</i> -inositol*	-6.091 ± 0.004	4	XYP β -D-xilopiranososa	0.961 ± 0.003
5	GAL β -D-galactopiranososa	-6.049 ± 0.011	4	RIP β -D-ribopiranososa	0.961 ± 0.003
6	RIP β -D-ribopiranososa	-6.003 ± 0.005	4	ARA α -L-arabinopiranososa	0.961 ± 0.003
7	ALL β -D-alopiranososa	-5.949 ± 0.004	7	HPA hipoxantina*	0.961 ± 0.007
8	GZL β -D-galactofuranosa	-5.783 ± 0.008	8	ALL β -D-alopiranososa	0.957 ± 0.010
9	PAV D-apiosa	-5.751 ± 0.011	9	BGC β -D-glucopiranososa	0.957 ± 0.009
10	FRU β -D-fructofuranosa	-5.725 ± 0.002	10	INS <i>mio</i> -inositol*	0.957 ± 0.006

En Vina quedan fuera del top-10 BDR (-5.71), BGC (-5.65), AHR (-5.50), WEB (-5.46), X9X* (-5.23) y 3VB (-4.97). En Boltz quedan fuera GAL (0.956) y PAV (0.954), que siguen dentro del empate, y WEB (0.949), 3VB (0.946), FRU (0.942) y X9X* (0.929).

2 · Pisos de ruido y empates

Criterio: dos ligandos empatan cuando la diferencia entre sus medias es menor que $2 \cdot \sqrt{(DE_1^2 + DE_2^2)}$, el doble del error de la diferencia.

- Vina: medido con 3 réplicas de semilla por ligando.** Las desviaciones estándar van de 0.002 a 0.018 kcal/mol y el rango máximo entre semillas es de 0.035 kcal/mol (BGC). Con este piso, **los 120 pares son distinguibles y no hay empates**; el par más cercano es HPA/INS, con $\Delta = 0.011$ frente a un umbral de 0.011. *Pero este piso solo mide la estocasticidad de la búsqueda, no el error de la función de puntaje.* Ese error ronda los 2 kcal/mol frente a datos experimentales y es mayor que el rango completo del panel (1.43 kcal/mol). El ranking de Vina es muy reproducible, pero eso no garantiza que sea correcto.
- Boltz-2: medido con los 15 modelos por ligando.** Las desviaciones estándar del ipTM van de 0.003 a 0.012 y el rango del panel es de solo 0.046. **Los 12 primeros empatan con el líder (AHR).** Solo WEB, 3VB, FRU y X9X se separan, y lo hacen hacia abajo. Solo 15 de los 120 pares superan el piso. El ipTM se reporta con 2 decimales por modelo, lo que agrega ± 0.005 de redondeo.

3 · Comparación de los dos métodos

Lig.	P. Vina	Vina	P. Boltz	ipTM	Δ	Lig.	P. Vina	Vina	P. Boltz	ipTM	Δ
XYP	1	-6.41	4	0.961	+3	PAV	9	-5.75	12	0.954	+3
ARA	2	-6.14	4	0.961	+2	FRU	10	-5.73	15	0.942	+5
HPA*	3	-6.10	7	0.961	+4	BDR	11	-5.71	2	0.973	-9
INS*	4	-6.09	10	0.957	+6	BGC	12	-5.65	9	0.957	-3
GAL	5	-6.05	11	0.956	+6	AHR	13	-5.50	1	0.975	-12
RIP	6	-6.00	4	0.961	-2	WEB	14	-5.46	13	0.949	-1
ALL	7	-5.95	8	0.957	+1	X9X*	15	-5.23	16	0.929	+1
GZL	8	-5.78	3	0.963	-5	3VB	16	-4.97	14	0.946	-2

- **El acuerdo es débil y no significativo:** Spearman $\rho = 0.39$ ($p = 0.14$) con ipTM, y $\rho = 0.43$ ($p = 0.10$) con ranking_score.
- **El mayor desacuerdo está en las furanosas.** AHR ($\Delta -12$), BDR ($\Delta -9$) y GZL ($\Delta -5$) quedan abajo en Vina y hasta arriba en Boltz. Una explicación posible para Vina: cada furanosa tiene una torsión activa más que su piranosa (AHR 5 frente a ARA 4, BDR 5 frente a RIP 4, GZL 7 frente a GAL 6), y el término de entropía conformacional de Vina penaliza cada torsión. Boltz no tiene esa penalización.
- **Los dos métodos colocan el ligando en el mismo lugar.** Todas las poses están en el bolsillo: en Vina, el centroide queda a ≤ 1.5 Å del centro del sitio y la pose toca 7-8 de los 8 residuos (Y38 S43 H45 R174 W197 D222 E248 C269); en Boltz, a ≤ 2.2 Å y con ≥ 6 de 8 contactos, en los 15 modelos. Al superponer el mejor modelo de Boltz sobre el receptor de Vina (por C α), la pose de Vina y la de Boltz difieren en **1.1-2.0 Å de RMSD de átomos pesados**. El desacuerdo está en el puntaje, no en la geometría.
- **Fórmulas idénticas.** Las 6 moléculas C₅H₁₀O₅ ocupan los puestos 1, 2, 6, 9, 11 y 13 en Vina, y 1, 2, 4, 4, 4 y 12 en Boltz. **El orden dentro de una misma fórmula no se reproduce entre métodos.** Los pares piranosa/furanosa del mismo azúcar se invierten: ARA/AHR queda 2.^º/13.^º en Vina y 4.^º/1.^º en Boltz; RIP/BDR, 6.^º/11.^º y 4.^º/2.^º.
- **Señuelos.** Ningún método rechaza a HPA ni a INS. En Vina quedan 3.^º y 4.^º, por delante de casi todos los azúcares. En Boltz quedan 7.^º y 10.^º, dentro del empate. Los dos métodos coinciden solo en poner al poliol acíclico X9X al fondo (15.^º y 16.^º).
- **Artefacto de Boltz-2.** En los 10 ligandos cuyo CCD tiene un átomo llamado **O1**, Boltz lo elimina: el OH anomérico de RIP, XYP, ARA, AHR, BDR, BGC, GAL, ALL y GZL, y el O del CH₂OH de FRU. INS, X9X, HPA, 3VB, WEB y PAV salen completos. Para las aldosas, **Boltz modela un residuo glicosilo y no el azúcar libre, así que no puede distinguir α de β** . Parte de la comparación con Boltz no se hace entre las mismas moléculas que dockeo Vina.

4 · Cadena de inferencias

Etapas	Herramienta	Entrada	Qué salió	Qué concluyo · qué no
1 BLAST	blastp 2.x local (Swiss-Prot) y remoto (nr)	362 aa	Swiss-Prot: 17 aciertos (E < 1e-3), todos de la familia RbsB, 22.6-31.5 % de identidad; 6 ligandos distintos entre los 10 primeros. nr: 500 aciertos, 259 de Rhizobiaceae	Es una proteína periplásmica de unión a azúcar, con pliegue de tipo I. No asigna ligando: la identidad está en zona crepuscular y los aciertos #1 y #2 unen ligandos distintos. Las anotaciones “ribose” de nr son automáticas y circulares
2 AlphaFold2	ColabFold (GPU de Colab), sin plantillas, 5 modelos	362 aa	pLDDT 92.2, pTM 0.877; MSA de 1841 secuencias; PAE entre lóbulos de 3.0 Å	Modelo confiable, con la hendidura cerrada. No muestra el ligando ni la conformación abierta
3 Péptido señal	análisis n/h/c, pLDDT, alineamiento de BLAST	modelo y secuencia	Corte 27/28	Cadena madura de 335 aa (ver §6)
4 Foldseek	foldseek local contra el PDB completo	madura, 1-335	2811 aciertos; TM-score de 0.76 a 0.92 con solo 17-25 % de identidad; 150 entradas, 83 con ligando	Recupera parientes que BLAST no ve. No dice qué ligando: C ₅ H ₁₀ O ₅ aparece con 11 códigos y C ₆ H ₁₂ O ₆ con 10
5 Ligandos	CCD_ideal.sdf del RCSB y Open Babel	16 códigos	mol2 y pdbqt; fórmula = ficha, con H, no planos	Panel listo. No incluye todos los tautómeros ni anómeros
6 Docking	Vina 1.2, caja de 26 Å, exhaustiveness 32, 3 semillas	receptor maduro y 16 ligandos	-6.41 a -4.97 kcal/mol; poses en el sitio	Ranking reproducible. No es afinidad: el error del puntaje es mayor que el rango
7 Co-plegamiento	Boltz-2, sin plantillas, 3 semillas × 5 muestras	secuencia madura y código CCD	ipTM medio de 0.93 a 0.98; 12 de 16 empatados	Todos los ligandos caben en el sitio. No discrimina entre azúcares. Artefacto O1

5 · Construcción del panel y predicción

De las 150 entradas únicas de Foldseek, 67 no tienen ligando (45 %). Conté los ligandos de las 83 restantes. El panel siguió cuatro criterios: **(a) frecuencia:** BGC (13: 2GBP, 3GBP, 2IPL...), RIP (9: 1DBP, 2FN8, 2IOY...), GAL (7: 2RJO, 8ABP...), XYP (4: 3C6Q, 5XSS...); **(b) convergencia con BLAST:** PAV (4: 3EJW, 3T95, 4PZO, 6DSP), la única función que aparece en Swiss-Prot en el mismo género, *Rhizobium*; **(c) pares que pusieran a prueba la geometría con la misma fórmula:** piranosa/furanosa (ARA 1BAP/4RXT frente a AHR 5OCP, RIP frente a BDR 3KSM, GAL frente a GZL 2VK2) y aldosa/cetosa (ALL 5DTE frente a WEB 8WLB, BGC frente a FRU 2X7X/3BRQ); **(d) señuelos de dificultad creciente:** INS (4: 4IRX...

ciclitol con la misma fórmula que BGC), X9X (4WT7, poliol acíclico) y HPA (6: 1JFT..., base púrica). 3VB (4RSM) viene del panel del tutorial. El panel tiene 6 ligandos $C_5H_{10}O_5$ y 7 $C_6H_{12}O_6$.

Predicción, formulada con las etapas 1-4: D-apiosa (PAV); segunda opción, ribosa. El acierto #1 de BLAST (RbsB, ribosa, 28.5 %) está en zona crepuscular, y el #2 (31.5 %) une treitol. La apiosa es el único ligando que aparece a la vez en Swiss-Prot (aciertos #8-#11, dos de ellos de *R. rhizogenes* y *R. etli*) y en Foldseek, y es coherente con la ecología de *Rhizobium*, asociado a plantas; la apiosa es un azúcar de la pared celular vegetal. *Declaración:* vi los scores de Vina antes de escribir la predicción, pero no los usé para formularla. **Resultado:** PAV queda 9.º en Vina y 12.º en Boltz, dentro del empate. Ningún método la confirma ni la descarta.

6 · Péptido señal y numeración

El corte está **después de A27**, y hay tres evidencias independientes: **(i) secuencia:** región n MKRRT (carga +3), región h FLQTGSALIAAGAFGIP (Kyte-Doolittle +1.27, con máximo de +2.24) y región c GILRA, que termina en Ala -1, con una caída de hidropatía en el residuo 28; **(ii) pLDDT:** 36.3 en los residuos 1-27 frente a 96.8 en 28-362, y un PAE señal-maduro de 29.6 Å; **(iii) BLAST:** ningún homólogo alinea antes del residuo 49. **Recorté el PDB (opción b)** en lugar de volver a predecir, con un costo que hay que declarar: el resto de la proteína se plegó en presencia del péptido señal. **Numeración madura 1-335.** *Nota:* al modelo de respaldo que se reparte (TeuB_modelo_apo.pdb) le falta una Arg en la posición 256 (WMRRW → WMRW), así que tiene 334 residuos. Por eso su Cys268 es C269 en la numeración correcta, y el centro de la caja se recalculó sobre el modelo propio: (3.38, -3.17, 0.79).

Veredicto

No: con lo que medí, no puedo decir qué ligando prefiere TeuB. Los dos métodos colocan todos los ligandos en el mismo bolsillo. Pero Boltz empata a 12 de 16 y Vina ordena con una precisión que su función de puntaje no respalda. Además, ninguno de los dos distingue un azúcar de un señuelo como la hipoxantina, y sus rankings no correlacionan ($p = 0.39$). Lo único que los dos sostienen es que **un poliol acíclico (X9X) es mal ligando**. La hipótesis mejor fundamentada, la D-apiosa, sigue apoyándose en la homología y en el contexto biológico, no en el cálculo.

Datos, scripts y registros: <https://github.com/jtuxman/tareaarcadioazucares> · 08_analisis/comparar.py, tabla_comparativa.tsv.