

TeuB: ¿qué azúcar une? Un ranking por dos métodos independientes

De una secuencia sin etiqueta a un ranking de ligandos · Evolución y Diseño de Proteínas 2027-1

jmanuel@ibt.unam.mx
28 de septiembre de 2026

Resumen. TeuB (362 aa, *Rhizobium*) es una proteína periplásmica de unión a azúcar de la familia RbsB. Su cadena madura tiene 335 aa, porque el péptido señal (1-27) se corta. Ordenamos un panel de 16 ligandos, sacado de Foldseek (13 candidatos y 3 señuelos), con **AutoDock Vina** (3 semillas) y **Boltz-2** (15 modelos). Medimos el piso de ruido de cada método. **Los dos métodos colocan todos los ligandos en el mismo bolsillo, pero no coinciden en el orden** (Spearman $\rho = 0.39$, $p = 0.13$). Boltz-2 empata a 12 de los 16, y ninguno de los dos rechaza a los señuelos hipoxantina e inositol. **No podemos decir qué azúcar prefiere TeuB.** Nuestra predicción previa, la D-apiosa, no queda confirmada ni descartada.

1 EL RANKING

#	Docking · AutoDock Vina	kcal/mol (media ± DE)	#	Co-plegamiento · Boltz-2	ipTM (media ± DE)
1	XYP β-D-xilopiranososa	-6.408 ± 0.008	1	AHR α-L-arabinofuranosa	0.975 ± 0.008
2	ARA α-L-arabinopiranososa	-6.145 ± 0.012	2	BDR β-D-ribofuranosa	0.973 ± 0.012
3	HPA hipoxantina señuelo	-6.102 ± 0.004	3	GZL β-D-galactofuranosa	0.963 ± 0.007
4	INS mio-inositol señuelo	-6.091 ± 0.004	4	XYP β-D-xilopiranososa	0.961 ± 0.003
5	GAL β-D-galactopiranososa	-6.049 ± 0.011	4	RIP β-D-ribopiranososa	0.961 ± 0.003
6	RIP β-D-ribopiranososa	-6.003 ± 0.005	4	ARA α-L-arabinopiranososa	0.961 ± 0.003
7	ALL β-D-alopiranososa	-5.949 ± 0.004	7	HPA hipoxantina señuelo	0.961 ± 0.007
8	GZL β-D-galactofuranosa	-5.783 ± 0.008	8	ALL β-D-alopiranososa	0.957 ± 0.010
9	PAV D-apiosa predicción	-5.751 ± 0.011	9	BGC β-D-glucopiranososa	0.957 ± 0.009
10	FRU β-D-fructofuranosa	-5.725 ± 0.002	10	INS mio-inositol señuelo	0.957 ± 0.006

Vina: la mejor pose de cada semilla (101, 202, 303), promediada. Boltz-2: ipTM de 15 modelos (semillas 1-3 × 5 muestras), sin plantillas.

Sombreado: empatado con el 1.º según el criterio de la §2. Fuera del top-10 quedan, en Vina, BDR -5.71, BGC -5.65, AHR -5.50, WEB -5.46, **X9X -5.23** y 3VB -4.97; en Boltz-2, GAL 0.956 y **PAV 0.954** (los dos todavía empatados con el 1.º), WEB 0.949, 3VB 0.946, FRU 0.942 y **X9X 0.929**.




Figura 1. (A) Puntaje de Vina ± DE entre semillas; las barras de error son más pequeñas que los puntos. (B) ipTM de Boltz-2 ± DE entre los 15 modelos; la banda marca a los 12 ligandos empatados con el primero. (C) Puesto en Vina contra puesto en Boltz-2; la diagonal indica acuerdo perfecto. **Rojo:** señuelos. **Ámbar:** predicción previa.

2 PISOS DE RUIDO Y EMPATES

Criterio: dos ligandos empatan si $|\Delta \text{media}| < 2 \cdot \sqrt{(\text{DE}_1^2 + \text{DE}_2^2)}$, el doble del error estándar de la diferencia (~95 %).

Vina · 3 réplicas de semilla por ligando

DE de **0.002 a 0.018 kcal/mol**; rango máximo entre semillas, 0.035 (BGC). Con este piso, **los 120 pares son distinguibles**. El más cercano es HPA/INS: $\Delta = 0.011$ frente a un umbral de 0.011.

Salvedad: este piso mide solo la estocasticidad de la búsqueda. El error de la función de puntaje frente a datos experimentales (~2 kcal/mol) es mayor que todo el rango del panel (**1.43 kcal/mol**). El ranking de Vina es *preciso*, pero no sabemos si es *exacto*.

Boltz-2 · 15 modelos por ligando

DE del ipTM de **0.003 a 0.012**; rango del panel, **0.046**. **Los 12 primeros empatan con el líder (AHR)**, y solo WEB, 3VB, FRU y X9X se separan, hacia abajo. Solo **15 de los 120 pares** superan el piso. El ipTM se reporta con 2 decimales por modelo, lo que agrega ±0.005 de redondeo.

Ejemplo: AHR (0.975 ± 0.008) frente a PAV (0.954 ± 0.008): $\Delta = 0.021 < 0.023$, **empate**.

3 COMPARACIÓN DE LOS DOS MÉTODOS

Ligando	P. Vina	P. Boltz	Δ	Ligando	P. Vina	P. Boltz	Δ
XYP	1	4	+3	PAV	9	12	+3
ARA	2	4	+2	FRU	10	15	+5
HPA	3	7	+4	BDR	11	2	-9
INS	4	10	+6	BGC	12	9	-3
GAL	5	11	+6	AHR	13	1	-12
RIP	6	4	-2	WEB	14	13	-1
ALL	7	8	+1	X9X	15	16	+1
GZL	8	3	-5	3VB	16	14	-2

- **El acuerdo es débil y no significativo:** Spearman $\rho = 0.39$ ($p = 0.13$) con ipTM, y 0.43 ($p = 0.10$) con ranking_score.
- **El mayor desacuerdo está en las furanosas.** AHR ($\Delta -12$), BDR (-9) y GZL (-5) quedan abajo en Vina y hasta arriba en Boltz-2. Una explicación plausible: cada furanosa tiene una torsión activa más que su piranosa (AHR 5 contra ARA 4, BDR 5 contra RIP 4, GZL 7 contra GAL 6), y Vina penaliza cada torsión; Boltz-2 no.
- **Los métodos coinciden en la geometría, no en el puntaje.** Todas las poses están en el bolsillo: en Vina, $a \leq 1.5 \text{ \AA}$ del centro del sitio y con 7-8 de los 8 residuos (Y38 S43 H45 R174 W197 D222 E248 C269) a $< 4 \text{ \AA}$; en Boltz-2, $a \leq 2.2 \text{ \AA}$ y con $\geq 6/8$, en los 15 modelos. Al superponer por C α , la pose de Vina y el mejor modelo de Boltz-2 difieren en **1.1-2.0 Å de RMSD**.
- **Fórmulas idénticas.** Las 6 moléculas C₅H₁₀O₅ ocupan los puestos 1, 2, 6, 9, 11 y 13 en Vina, y 1, 2, 4, 4, 4 y 12 en Boltz-2. Los pares piranosa/furanosa **se invierten**: ARA/AHR queda 2.º/13.º en Vina y 4.º/1.º en Boltz-2.
- **Señuelos.** Ningún método rechaza a **HPA** ni a **INS**. Los dos coinciden solo en poner al poliol acíclico **X9X** al fondo.

Artefacto de Boltz-2 (declarado). En los 10 ligandos cuya ficha del CCD tiene un átomo llamado **O1**, Boltz-2 lo elimina: el OH anomérico de RIP, XYP, ARA, AHR, BDR, BGC, GAL, ALL y GZL, y el O del CH₂OH de FRU. INS, X9X, HPA, 3VB, WEB y PAV salen completos. Para las aldosas, Boltz-2 modela un residuo glicosilo y no el azúcar libre, y no distingue α de β . Parte de la comparación no se hace entre las mismas moléculas.

4 CADENA DE INFERENCIAS

Etapas	Herramienta	Entrada	Resultado	Qué concluimos · qué <u>no</u>
BLAST	blastp: Swiss-Prot (local) y nr (remoto)	362 aa	17 aciertos RbsB, 22.6-31.5 % id, 6 ligandos distintos en el top-10; nr: 500 aciertos, 259 de Rhizobiaceae	Familia y pliegue tipo I. <u>No</u> el ligando: zona crepuscular, y #1 y #2 unen cosas distintas. Las anotaciones "ribose" de nr son automáticas y circulares
AlphaFold2	ColabFold 1.6, sin plantillas, 5 modelos	362 aa	pLDDT 92.2, pTM 0.877; MSA de 1841; dos lóbulos, PAE entre ellos 3.0 Å	Modelo confiable, hendidura cerrada. <u>No</u> la función ni la conformación con ligando
Péptido señal	n/h/c, pLDDT, BLAST	modelo + secuencia	corte 27/28	Cadena madura de 335 aa (ver §6)
Foldseek	foldseek, PDB completo (local)	madura 1-335	2811 aciertos; TM 0.76-0.92 con solo 17-25 % id; 150 entradas, 83 con ligando	Parientes que BLAST no ve. <u>No</u> el ligando: C ₅ H ₁₀ O ₅ con 11 códigos, C ₆ H ₁₂ O ₆ con 10
Ligandos	CCD_ideal.sdf + Open Babel	16 códigos	fórmula = ficha, con H, no planos (HPA es aromática)	Panel listo. <u>No</u> cubre todos los anómeros ni tautómeros
Docking	Vina 1.2, caja de 26 Å, exh. 32, 3 semillas	receptor + 16	-6.41 a -4.97 kcal/mol; poses en el sitio	Reproducibile. <u>No</u> es afinidad: el error del puntaje es mayor que el rango
Co-plegamiento	Boltz-2, sin plantillas, 3 x 5	madura + CCD	ipTM medio 0.93-0.98; 12 de 16 empatados	Todos caben en el sitio. <u>No</u> discrimina entre azúcares. Artefacto O1

5 CONSTRUCCIÓN DEL PANEL Y PREDICCIÓN

De las **150 entradas únicas** de Foldseek, 67 no tienen ligando (45 %). Contamos los ligandos de las 83 restantes, después de descartar iones, crioprotectores y tampones. El panel siguió cuatro criterios explícitos:

Criterio	Ligandos (entradas PDB de origen)	Qué pone a prueba
(a) Frecuencia	BGC x13 (2GBP, 3GBP, 2IPL...), RIP x9 (1DBP, 2IOY...), GAL x7 (2RJO, 8ABP...), XYP x4 (3C6Q, 5XSS...)	lo más observado en la familia
(b) Convergencia BLAST + Foldseek	PAV x4 (3EJW, 3T95, 4PZ0, 6DSP)	la única función presente en Swiss-Prot en el mismo género, <i>Rhizobium</i>
(c) Misma fórmula, otra geometría	ARA (1BAP) / AHR (5OCP); RIP / BDR (3KSM); GAL / GZL (2VK2); ALL (5DTE) / WEB (8WLB); BGC / FRU (2X7X)	anillo de 6 frente a 5 · aldosa frente a cetosa
(d) Señuelos	INS (4IRX), X9X (4WT7), HPA (1JFT)	ciclitol · poliol acíclico · base púrica

Además incluimos 3VB (4RSM, del panel del tutorial). El panel tiene 6 ligandos $C_5H_{10}O_5$ y 7 $C_6H_{12}O_6$.

Predicción (con la evidencia de las etapas 1-4): D-apiosa (PAV); segunda opción, ribosa. El acierto #1 de BLAST (ribosa, 28.5 %) está en zona crepuscular, y el #2 (31.5 %) une treitol. La apiosa es el único ligando con evidencia en Swiss-Prot (#8-#11, dos de ellos de *R. rhizogenes* y *R. etli*) y en Foldseek, y encaja con la ecología: *Rhizobium* vive en las raíces y la apiosa es un azúcar de la pared celular vegetal. **Declaración:** vimos los scores de Vina antes de escribirla, pero no los usamos para formularla. **Resultado:** 9.^º en Vina y 12.^º en Boltz-2, dentro del empate. No se confirma ni se descarta.

6 PÉPTIDO SEÑAL Y NUMERACIÓN

(i) Secuencia

n MKRRT (+3) · h FLQTGSALIAAGAFGIP
(Kyte-Doolittle +1.27, máximo +2.24)
· c GILRA, que termina en Ala. La hidropatía cae en el residuo 28.

(ii) Confianza del modelo

pLDDT **36.3** en 1-27 frente a **96.8** en 28-362. PAE señal-madura de **29.6 Å**: el modelo no sabe dónde colocar el péptido.

(iii) Homología

Ningún homólogo de Swiss-Prot alinea antes del residuo **49** (la mediana es 88).

Corte después de A27. Recortamos el PDB (opción b) en lugar de volver a predecir. Costo que declaramos: el resto se plegó en presencia del péptido. **Numeración madura 1-335**, con D28 del precursor = 1. *Nota:* al modelo de respaldo que se reparte (TeuB_modelo_apo.pdb) le falta una Arg en la posición 256 (WMRRW → WMRW), así que tiene 334 residuos y su "Cys268" es C269. Por eso recalculamos el centro de la caja en el modelo propio: (3.38, -3.17, 0.79).

Veredicto. No: con lo que medimos, no podemos decir qué ligando prefiere TeuB. Los dos métodos colocan todos los ligandos en el mismo bolsillo, pero Boltz-2 empata a 12 de los 16 y Vina ordena con una precisión que su función de puntaje no respalda. Ninguno distingue un azúcar de la hipoxantina, y sus rankings no correlacionan ($\rho = 0.39$). Lo único que ambos sostienen es que el poliol acíclico X9X es mal ligando. La hipótesis mejor fundamentada, la D-apiosa, sigue apoyándose en la homología y el contexto biológico, no en el cálculo.

Métodos, declarados: BLAST, Foldseek y Vina se corrieron localmente (los mismos motores que los servidores web); AlphaFold2 y Boltz-2 se corrieron en Google Colab (GPU T4). Los datos, los scripts y los registros completos están en github.com/jtuxman/tarearcardioazucares.